Mini Projeto:
Preços de Combustíveis no Brasil

Concatenação de bases · ANP Série Histórica · Outliers em dados reais

Prof. Cassio Ribeiro | SENAC RJ

A base de dados: ANP

A Agência Nacional do Petróleo (ANP) realiza uma pesquisa semanal de preços em postos revendedores de todo o Brasil. Os dados são públicos e disponibilizados no portal de dados abertos do governo federal. LINK

> Cada linha = **um registro de preço de um posto revendedor em uma semana específica.**

Coluna	Tipo	Exemplo
Estado - Sigla	Qualitativa	RJ, SP, MG
Municipio	Qualitativa	Rio de Janeiro, Niterói
Produto	Qualitativa	Gasolina C, Etanol Hidratado
Bandeira	Qualitativa	Petrobras, Shell, Branca
Valor de Venda	Quantitativa	5.89, 6.12
Valor de Compra	Quantitativa	5.20, 5.45
Data da Coleta	Data	2023-01-08

Por que a base vem dividida por semestre?

A ANP publica os dados em arquivos semestrais — cada arquivo cobre 6 meses de coletas. Para analisar um período maior, é necessário unir os arquivos.

2024 — 1º Sem	2024 — 2º Sem	2025 — 1º Sem	2025 — 2º Sem
`ca-2024-01.csv`	`ca-2024-02.csv`	`ca-2025-01.csv`	`ca-2025-02.csv`

Um único DataFrame consolidado — 2024 e 2025 completos

Isso é muito comum no mundo real: sistemas exportam dados por período e o analista consolida antes de analisar.

Atenção: separador decimal nos dados brasileiros

Antes de carregar a base, é preciso entender como os valores numéricos estão formatados no arquivo.

No arquivo CSV

O valor está escrito com vírgula:

```
5,89
```

Se lido sem o parâmetro decimal, o Pandas interpreta como texto (object) — e qualquer cálculo matemático falhará com erro.

No DataFrame

Com decimal=',' o Pandas converte automaticamente:

```
5.89 → float64
```

O valor entra como número de ponto flutuante — pronto para np.mean(), np.percentile() e qualquer cálculo.

```
pd.read_csv('arquivo.csv', sep=';', decimal=',')
```

O parâmetro decimal não altera o arquivo original — apenas instrui a leitura.

Carregando cada semestre

```python
import pandas as pd
import numpy as np

df_2024_1 = pd.read_csv('ca-2024-01.csv', sep=';', decimal=',')
df_2024_2 = pd.read_csv('ca-2024-02.csv', sep=';', decimal=',')
df_2025_1 = pd.read_csv('ca-2025-01.csv', sep=';', decimal=',')
df_2025_2 = pd.read_csv('ca-2025-02.csv', sep=';', decimal=',')
```

Todos os arquivos têm exatamente as mesmas colunas — condição necessária para concatenar com segurança.

Concatenando com pd.concat()

Com os quatro DataFrames carregados, unimos tudo em um único usando pd.concat():

```
df = pd.concat([df_2024_1, df_2024_2,
                df_2025_1, df_2025_2],
               ignore_index=True)

print(df.shape)   display(df.head())
```

pd.concat([lista])

Recebe uma lista com os DataFrames a unir e os empilha verticalmente — as linhas de cada um são somadas na sequência.

ignore_index=True

Reinicia a numeração dos índices no DataFrame final. Sem isso, os índices originais se repetem, o que causa problemas em filtros futuros.

Média, não soma: por quê?

A estrutura da base ANP determina qual operação faz sentido analítico.

Cada linha da base representa o preço praticado por um posto em uma semana.

Somar preços de postos diferentes não produz nenhuma informação útil. O que representa o mercado é a média — o comportamento central dos preços.

Não faz sentido

```
# Soma de precos de postos diferentes
df['Valor de Venda'].sum()
```

Resultado sem interpretação — não representa nada.

Faz sentido

```
# Preco medio praticado no periodo
df['Valor de Venda'].mean()
```

Representa o comportamento central do mercado.

No groupby, sempre use **.mean()** para agregar **Valor de Venda** — jamais **.sum()**

Mini Projeto — Contexto

Contexto

Você foi contratado como analista de dados por uma consultoria que monitora preços de combustíveis no Brasil. A diretoria quer um relatório sobre o comportamento dos preços de 2024 a 2025, identificando padrões e postos com comportamento fora do padrão. Os dados vêm diretamente da ANP — divididos por semestre. Cabe a você consolidá-los e extrair as respostas.

O que este mini projeto exige:

Aula 02	pd.read_csv() com parâmetros reais, groupby + sort_values(), loc / query()
Aula 02	np.array(), np.percentile() para Q1 e Q3
Aula 03	np.mean(), np.median(), distância média-mediana
Aula 04	IQR, limites superior e inferior, outliers ordenados
Hoje	pd.concat() com ignore_index=True, decimal=','

Mini Projeto — Problemas 1 e 2

01

Construção da base consolidada

O sistema da ANP exporta os dados por semestre. Antes de qualquer análise, consolide os quatro arquivos de 2024 e 2025 em um único DataFrame. Confirme que a operação foi realizada corretamente verificando o número de linhas e as primeiras entradas do resultado.

02

Gasolina C no Rio de Janeiro

O diretor quer entender como se comportaram os preços médios da Gasolina C no estado do Rio de Janeiro entre 2024 e 2025. Calcule a média do Valor de Venda por município e apresente os resultados do maior para o menor. Quais municípios praticaram os maiores preços médios no período?

Mini Projeto — Problemas 3 e 4

03

Outliers de preço: Gasolina C no RJ

Ainda com foco na Gasolina C no Rio de Janeiro, identifique os postos com preços estatisticamente atípicos. Calcule o IQR e os limites para o Valor de Venda. Existem postos praticando preços fora do padrão? Apresente os grupos de outliers superiores e inferiores ordenados de forma adequada. Se o limite inferior for negativo, o que isso indica?

04

Comparando estados: Etanol Hidratado

O diretor quer comparar o preço médio do Etanol Hidratado entre RJ e SP em 2024 e 2025. Filtre os dados para os dois estados e calcule a média do Valor de Venda para cada um. Em seguida, aplique o critério de outliers em cada estado separadamente. Os limites e os casos atípicos são semelhantes ou diferentes entre os dois estados?

Mini Projeto — Problema 5

05

Bairros da capital: preços dentro ou fora do padrão?

A diretoria quer entender como os preços da Gasolina C se distribuem entre os diferentes bairros da cidade do Rio de Janeiro. Existem bairros com dados atípicos?

A partir desse recorte:

1. Calcule a média do Valor de Venda por bairro (coluna Bairro) e ordene do maior para o menor.
2. Aplique o IQR para identificar bairros com preços médios estatisticamente atípicos — tanto os superiores quanto os inferiores.
3. Os bairros outliers superiores são regiões nobres da cidade? Os inferiores são periferias ou regiões com alta concorrência? Apresente sua conclusão.

O que vimos hoje

- decimal=',' converte vírgula em float durante a leitura — sem trabalho adicional
- pd.concat([lista], ignore_index=True) — consolida bases com a mesma estrutura
- Na base ANP: sempre média, nunca soma de Valor de Venda
- Colunas com espaços no .query() exigem backticks (`)
- IQR e outliers aplicados a dados reais com filtros combinados