UC2 – AULA 03

Arrays e Medidas de Tendência Central

Criação de arrays com NumPy · Média e mediana · Distância entre medidas · Coluna derivada

Prof. Cassio Ribeiro | SENAC RJ

Recapitulando

Aula 01

DataFrame, pd.read_excel(), usecols, agregações básicas com Pandas

Aula 02

Exploração do DataFrame, groupby + reset_index(), filtros com .loc e .query(), quartis com np.percentile()

Hoje

Arrays NumPy, np.mean(), np.median(), distância entre medidas, coluna derivada

NumPy: o que é um array?

Array é uma estrutura do NumPy para armazenar sequências de valores numéricos.
Diferente de uma lista Python, arrays permitem operações matemáticas diretamente sobre todos os elementos.

Lista Python

```
lista = [10, 20, 30]
lista * 2

# [10, 20, 30, 10, 20, 30]
```

⚠ Duplica a lista — não multiplica os valores

Array NumPy

```
array = np.array([10, 20, 30])
array * 2

# [20, 40, 60]
```

✓ Multiplica cada elemento individualmente

Arrays são ideais para cálculos estatísticos em grandes volumes de dados.

Criando um array a partir do DataFrame

Para calcular estatísticas com NumPy, primeiro convertemos uma coluna do DataFrame em array:

```
array_roubos = np.array(df['roubo_veiculo'])
print(array_roubos)
```

```
[ 312  489  201  674  128  543  390  267  ...]
```

① **np.array()**

Função que converte
uma coluna em array NumPy

② **df['coluna']**

Seleciona a coluna
do DataFrame como série

③ **Resultado**

Um vetor numérico
pronto para cálculos

Medidas de tendência central

Resumem um conjunto de dados em um único valor representativo.

Média

Soma de todos os valores dividida pela quantidade.

⚠ **Sensível a valores extremos**

Um único valor muito alto ou baixo pode distorcer a média e torná-la não representativa.

Mediana

Valor central quando os dados estão ordenados.

✓ **Robusta a valores extremos**

Não é afetada por outliers. Representa o "centro real" dos dados.

💡 **Lembre-se: a mediana equivale ao Q2 — o valor que divide os dados ao meio.**

Calculando média e mediana com NumPy

Usando as funções mean() e median() do NumPy sobre o array criado anteriormente:

```
1
2  array_roubos = np.array(df['roubo_veiculo'])
3  media   = np.mean(array_roubos)
   mediana = np.median(array_roubos)
4
5  print(f"Média:   {media:.2f}")
   print(f"Mediana: {mediana:.2f}")
6
```

`np.mean()`

Calcula a média aritmética
de todos os valores do array

`np.median()`

Calcula a mediana —
o valor central do array ordenado

A distância entre média e mediana

Por que comparar as duas medidas?

≈

Quando são próximas

Os dados estão bem distribuídos ao redor do centro. A média tende a ser um bom resumo.

≠

Quando se distanciam

Valores extremos estão puxando a média para cima ou para baixo. A média pode estar enganando.

?

Como decidir?

Precisamos medir essa distância em percentual para saber qual medida usar como referência.

Só comparar os números absolutos não basta — precisamos de uma medida relativa.

Fórmula e código da distância

distância = (média – mediana) / mediana

```
distancia = (media - mediana) / mediana

print(f"Distância: {distancia:.2%}")
```

:.2% → Formata o número como percentual com 2 casas decimais. Ex: 0.1532 é exibido como **15.32%**

Interpretando a distância

Distância ≤ |10%| — **Média confiável**

A média tende a ser uma boa medida de tendência central. Os extremos exercem pouca influência sobre ela.

|10%| < Distância < |25%| — **Atenção — influência moderada**

A média está sofrendo alguma influência dos valores extremos. Pode ou não ser confiável — será necessário analisar outras medidas no futuro.

Distância ≥ |25%| — **Média não confiável**

Alta influência dos valores extremos. A média está distorcida e tende a não representar bem os dados. Prefira a mediana.

Direção da influência

Quando a distância é relevante, identifique de qual lado os extremos estão puxando:

Média > Mediana

Os valores maiores da distribuição estão puxando a média para cima.

Média < Mediana

Os valores menores da distribuição estão puxando a média para baixo.

```
if media > mediana:
    print("Influência dos valores maiores da distribuição")
else:
    print("Influência dos valores menores da distribuição")
```

Exemplo completo — dataset ISP-RJ

Variável utilizada: roubo_transeunte (não utilizada nas aulas anteriores)

```
array_var = np.array(df['roubo_transeunte'])

media   = np.mean(array_var)
mediana = np.median(array_var)
dist    = (media - mediana) / mediana

print(f"Média:     {media:.2f}")
print(f"Mediana:   {mediana:.2f}")
print(f"Distância: {dist:.2%}")
```

1. Criar array
2. Calcular média e mediana
3. Calcular distância
4. Interpretar resultado
5. Identificar direção

VAMOS DEBATER!

Criando uma coluna derivada

Às vezes o DataFrame não vem completo do sistema. O analista pode construir novas colunas a partir de colunas existentes.

ANTES — dados do sistema

quantidade	valor_unitario
2	R$ 1.299,00
1	R$ 89,90
3	R$ 499,00
1	R$ 2.799,00

DEPOIS — coluna calculada

quantidade	valor_unitario	valor_pedido ✨
2	R$ 1.299,00	R$ 2.598,00
1	R$ 89,90	R$ 89,90
3	R$ 499,00	R$ 1.497,00
1	R$ 2.799,00	R$ 2.799,00

```
df['valor_pedido'] = df['quantidade'] * df['valor_unitario']
```

Será o primeiro passo da atividade prática — os dados da NaraShop chegam sem essa coluna.

Atividade Prática — NaraShop

Você é analista de dados da NaraShop. O gerente comercial e o diretor de vendas precisam de respostas sobre o desempenho do último trimestre. Eles não sabem Python — querem apenas os resultados. O arquivo pedidos_narashop.csv está disponível.

01 O sistema exportou os pedidos sem calcular o valor total de cada um. Corrija isso no DataFrame antes de iniciar qualquer análise.

02 O gerente quer saber quais categorias geraram mais receita. Apresente o faturamento total por categoria, do maior para o menor.

03 A diretoria precisa de um recorte para auditoria: pedidos com status 'Entregue' e valor total acima de R$ 500.

04 O diretor de operações quer identificar extremos no mix de produtos. Use Q1 e Q3 como corte: quais produtos estão no grupo dos 25% que mais faturam e no grupo dos 25% que menos faturam?

05 O diretor de vendas suspeita de desigualdade entre vendedores. Aplique a mesma lógica de Q1 e Q3 ao faturamento por vendedor e identifique os dois grupos extremos.

06 O gerente afirma que 'o ticket médio da NaraShop é de R$ 800'. Verifique. A média é confiável para representar o valor típico de um pedido? Calcule a distância e apresente uma resposta fundamentada.