UC2 – AULA 04

Outliers: Identificação e Tratamento

IQR · Limites superior e inferior · Outliers · Ordenação de resultados

Prof. Cassio Ribeiro | SENAC RJ

O que é um outlier?

Outliers são valores que se distanciam significativamente dos demais dados de uma distribuição.

Erros de registro

Um valor digitado incorretamente pode se comportar como outlier — por exemplo, um salário de R$ 999.999 numa base de dados de estagiários.

Eventos raros mas reais

Uma delegacia que concentra registros de uma área de altíssima criminalidade pode aparecer como outlier mesmo que o dado seja correto.

Por que isso importa?

Ignorar outliers pode distorcer médias, totais e qualquer análise estatística. Identificá-los é o primeiro passo para tratá-los corretamente.

Como identificar outliers? O IQR

O Intervalo Interquartil (IQR) é a base do critério mais utilizado para identificação de outliers.

$$IQR = Q3 - Q1$$

A partir do IQR, calculamos os limites que definem a "zona normal" dos dados:

Limite Superior

$$Q3 + (1.5 \times IQR)$$

Limite Inferior

$$Q1 - (1.5 \times IQR)$$

O fator 1.5 é uma convenção estatística amplamente utilizada. Valores além desses limites são candidatos a outlier.

Outliers superiores e inferiores

Outlier Superior

valor > limite superior

Ex: produto que faturou muito acima dos demais

Outlier Inferior

valor < limite inferior

Ex: delegacia com registros muito abaixo das demais

⚠ **Atenção: limite inferior negativo**

Quando o limite inferior calculado for negativo e a variável só admite valores positivos (contagens, faturamento, quantidades), não há outliers inferiores — todos os dados já estão acima do limite por definição. O resultado do cálculo precisa ser interpretado no contexto dos dados, não aplicado mecanicamente.

Situações onde outliers fazem sentido:

- Produto que vendeu muito mais (ou menos) que os demais
- Delegacia com número atípico de registros de crime
- Estado com receita muito acima ou abaixo da média nacional

Calculando IQR e limites no Python

Usando o dataset ISP-RJ — variável roubo_veiculo:

```python
array_var = np.array(df['roubo_veiculo'])

q1 = np.percentile(array_var, 25)
q3 = np.percentile(array_var, 75)

iqr = q3 - q1
limite_superior = q3 + (1.5 * iqr)
limite_inferior = q1 - (1.5 * iqr)

print(f"Limite superior: {limite_superior}")
print(f"Limite inferior: {limite_inferior}")
```

Reutilizamos **np.percentile()** da Aula 02 — agora Q1 e Q3 servem como base para calcular os limites.

Filtrando os outliers

Com os limites calculados, usamos .query() para isolar os casos extremos:

Outliers Superiores

```
outliers_sup = df.query("roubo_veiculo > @limite_superior")
```

Outliers Inferiores

```
outliers_inf = df.query("roubo_veiculo < @limite_inferior")
```

@limite_superior → O prefixo **@** dentro do **.query()** permite referenciar variáveis Python definidas fora do DataFrame.

Alternativa com .loc:

```
outliers_sup = df.loc[df['roubo_veiculo'] > limite_superior]
```

Exibindo resultados ordenados

Outliers precisam ser apresentados de forma ordenada para facilitar a leitura e a tomada de decisão:

Superiores — decrescente (do maior para o menor)

```
outliers_sup = outliers_sup.sort_values(by='roubo_veiculo', ascending=False)
```

Inferiores — crescente (do menor para o maior)

```
outliers_inf = outliers_inf.sort_values(by='roubo_veiculo', ascending=True)
```

```
display(outliers_sup)  display(outliers_inf)
```

Exemplo completo — dataset ISP-RJ

Variável: roubo_veiculo | Sequência completa do início ao fim:

```python
array_var = np.array(df['roubo_veiculo'])

q1 = np.percentile(array_var, 25)
q3 = np.percentile(array_var, 75)
iqr             = q3 - q1
limite_superior = q3 + (1.5 * iqr)
limite_inferior = q1 - (1.5 * iqr)

outliers_sup = df.query("roubo_veiculo > @limite_superior")
outliers_inf = df.query("roubo_veiculo < @limite_inferior")
outliers_sup = outliers_sup.sort_values(by='roubo_veiculo',
ascending=False)
outliers_inf = outliers_inf.sort_values(by='roubo_veiculo',
ascending=True)
display(outliers_sup)
display(outliers_inf)
```

1. Criar array
2. Calcular Q1 e Q3
3. Calcular IQR
4. Definir limites
5. Filtrar outliers
6. Ordenar e exibir
7. Debater

Atividade Prática

Dois cenários, uma mesma missão: identificar os casos fora do padrão e apresentá-los de forma clara e ordenada.

01

NaraShop — Produtos fora do padrão

O gerente quer entender quais produtos têm comportamento extremo de faturamento. Usando o faturamento total por produto, calcule o IQR e os limites. Quais produtos são outliers superiores e quais são outliers inferiores? Apresente cada grupo ordenado de forma adequada.

02

NaraShop — Vendedores fora do padrão

O diretor de vendas quer identificar os casos extremos entre os vendedores. Aplique a mesma lógica ao faturamento por vendedor e apresente os grupos de outliers, ordenados.

03

ISP-RJ — Delegacias da capital

A Secretaria de Segurança Pública está revisando a alocação de recursos nas delegacias do município do Rio de Janeiro. Filtre apenas as delegacias da capital, calcule o IQR e os limites para furto_veiculo e identifique as delegacias com comportamento estatisticamente atípico — tanto as que registraram volumes excepcionalmente altos quanto as que registraram volumes excepcionalmente baixos. Apresente cada grupo ordenado.

O que vimos hoje

- Conceito de outlier e sua importância na análise de dados
- IQR = Q3 − Q1 como base para identificação
- Limite superior = Q3 + (1.5 × IQR) e limite inferior = Q1 − (1.5 × IQR)
- Limite inferior negativo: quando a variável é positiva, não há outliers inferiores
- Filtragem com .query() e .loc[]
- sort_values(by=, ascending=) para ordenar os resultados