Análise de Dados com Python

Variância, Desvio Padrão, Covariância e Correlação

Aprendendo com NumPy e Pandas — do jeito fácil!

Prof. Cassio Ribeiro | SENAC RJ

O que já sabemos 🧠

Uma revisão rápida antes de continuar

📊 Mediana

O valor do meio — divide os dados em dois grupos iguais.

📦 Q1, Q3 e IQR

Quartis que mostram como os dados se distribuem em 4 partes.

📏 Média vs Mediana

Compara o centro dos dados e revela se há valores extremos.

🚨 Outliers

Valores que fogem do padrão e podem distorcer a análise.

O que vamos aprender hoje 🎯

Quatro conceitos novos — todos conectados!

1

Variância

Mede o quanto os dados se afastam da média. Quanto maior, mais espalhados.

2

Desvio Padrão

A 'raiz' da variância — mais fácil de interpretar, mesma unidade dos dados.

3

Covariância

Verifica se duas variáveis 'andam juntas' — sobem ou descem ao mesmo tempo.

4

Correlação

Mede a FORÇA da relação entre duas variáveis — escala de -1 a +1.

Nosso conjunto de dados 📋

Notas e horas de estudo de 8 alunos fictícios

Aluno	Nota (0–10)	Horas de Estudo
Ana	8.5	6
Bruno	6.0	3
Carol	9.2	8
Diego	5.5	2
Elisa	7.8	5
Felipe	4.0	1
Gabi	9.0	7
Hugo	6.5	4

💡 **Perceba:**

→ Alunos com mais horas de estudo tendem a ter notas mais altas.

→ Felipe estudou pouco (1h) e teve a menor nota.

→ Carol estudou bastante (8h) e teve a maior nota.

→ Esse padrão será confirmado pela covariância e correlação! 📈

Variância — Passo a Passo 🧮

Entenda o raciocínio antes de ver o código

🎯 Ideia central: a variância responde à pergunta "os dados estão concentrados ou espalhados em torno da média?"

Passo 1 — Calcule a média

Some todos os valores e divida pela quantidade.

Ex: $(4 + 6 + 8) \div 3 = 6$

Passo 2 — Calcule a distância²

Subtraia a média de cada valor e eleve ao quadrado.

$(4-6)^2=4$ $(6-6)^2=0$ $(8-6)^2=4$

Passo 3 — Tire a média das distâncias²

Some os quadrados e divida pela quantidade.

$(4 + 0 + 4) \div 3 = 2.67$

⚠️ Por que elevar ao quadrado? Para evitar que distâncias negativas e positivas se cancelem e resultem em zero!

Variância no Python

np.var() com nosso dataset de alunos

```python
import numpy as np
import pandas as pd

dados = {
    'aluno':  ['Ana','Bruno','Carol','Diego',
               'Elisa','Felipe','Gabi','Hugo'],
    'nota':   [8.5, 6.0, 9.2, 5.5, 7.8, 4.0, 9.0, 6.5],
    'horas':  [6,   3,   8,   2,   5,   1,   7,   4  ]}

df = pd.DataFrame(dados)

# Variância das notas
variancia = np.var(df['nota'])
print(f"Variância: {variancia:.2f}")
# Saída: Variância: 3.02
```

▶ **Saída:**

```
Variância: 3.02
```

💡 **O que significa 3.02?**

Em média, cada nota está afastada 3.02 pontos² da média geral.

Como a unidade fica em "pontos ao quadrado", usamos o Desvio Padrão para interpretar melhor! (próximo slide →)

Desvio Padrão — A Mais Usada! ⭐

É a raiz quadrada da variância

🤔 **Por que usar desvio padrão e não variância?**

A variância eleva ao quadrado → a unidade fica "nota²", o que é difícil de interpretar.
O desvio padrão tira a raiz quadrada e volta à mesma unidade original: "nota".
Assim fica muito mais fácil dizer: "as notas variam em média ±1.74 pontos".

📐 **Fórmula:**

$\sigma = \sqrt{\text{variância}} \rightarrow \sqrt{3.02} \approx 1.74$

σ ≈ 0	σ médio	σ alto
Baixíssimo	**Moderado**	**Elevado**
Todos os valores são quase iguais. Muito consistente!	Existe alguma variação, mas não é extrema.	Dados muito espalhados. Alta variação!

Desvio Padrão no Python

np.std() — como usar na prática

```python
# Desvio padrão das notas
desvio = np.std(df['nota'])
print(f"Desvio Padrão: {desvio:.2f}")
# Saída: Desvio Padrão: 1.74

# Interpretando com a média
media = np.mean(df['nota'])
print(f"Média das notas: {media:.2f}")
print(f"Faixa típica: {media-desvio:.2f} até {media+desvio:.2f}")
# Saída:
# Média das notas: 7.06
# Faixa típica: 5.32 até 8.80
```

▶ **Resultado:**

```
Média: 7.06
Desvio: ±1.74
Faixa típica: 5.32 → 8.80
```

💡 **O que isso significa?**

A maioria dos alunos tem notas entre 5.32 e 8.80.

Abaixo de 5.32 → desempenho abaixo do esperado.

Acima de 8.80 → aluno se destaca.

Desvio Padrão vs Margem de Erro ⚠️

Dois conceitos parecidos — mas com propósitos diferentes

❓ *"Mas professor, isso não é igual à margem de erro que vejo nas pesquisas eleitorais?" — Quase, mas não é a mesma coisa!*

📊 Desvio Padrão

Fala sobre os DADOS em si.

Mede o quanto os valores do seu conjunto variam entre si.

Exemplo:
"As notas dos alunos têm desvio padrão de 1.74."

→ Significa que os valores estão moderadamente espalhados em torno da média 7.06.

📰 Margem de Erro

Fala sobre a ESTIMATIVA.

Mede a incerteza de uma pesquisa baseada em amostra.

Exemplo:
"Candidato tem 40% ± 2% de intenção de votos."

→ Significa que o valor real está entre 38% e 42% com certa confiança.

🔑 **Resumo: o desvio padrão descreve os dados. A margem de erro descreve a confiança na estimativa.**

Covariância — Duas variáveis juntas 🤝

Será que notas e horas de estudo caminham juntas?

🎒 **Analogia:**

Se dois amigos sempre chegam à escola juntos, eles têm uma relação positiva. A covariância faz isso com duas colunas: verifica se quando uma sobe, a outra também sobe.

📈 Positiva

Quando X sobe, Y também sobe.
Ex: mais estudo → nota maior.

📉 Negativa

Quando X sobe, Y desce.
Ex: mais faltas → nota menor.

➖ Zero

Nenhuma relação entre X e Y.
Ex: altura e nota.

Covariância no Python

np.cov() — retorna uma matriz com os valores

```
matriz_cov = np.cov(df['nota'], df['horas'])
print(matriz_cov)
# [[3.46  4.48]
#  [4.48  6.00]]

# Extraindo só o valor da covariância
cov_valor = matriz_cov[0, 1]
print(f"Covariância: {cov_valor:.2f}")
# Saída: Covariância: 4.48

# Forma alternativa com Pandas
print(df[['nota','horas']].cov())
#         nota    horas
# nota   3.456   4.479
# horas  4.479   6.000
```

🔢 Matriz de Covariância:

3.46 ← var(notas)	4.48
4.48	**6.00 ← var(horas)**

💡 Interpretação:

Covariância = 4.48 > 0
→ Relação POSITIVA!
Mais horas de estudo
tende a = nota maior.

Mas qual é a FORÇA
dessa relação? → Correlação!

Correlação — A Força da Relação 💪

A covariância diz SE existe relação. A correlação diz O QUANTO é forte.

🔑 Problema da covariância: o valor dela depende da escala dos dados.
Se as notas fossem de 0 a 100, a covariância seria enorme — mas a relação seria a mesma!
A correlação resolve isso: normaliza o valor para sempre ficar entre -1 e +1.

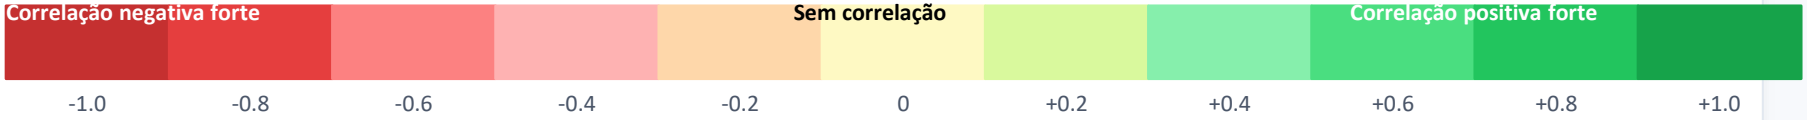

r ≈ +1 Mais horas de estudo → nota mais alta

r ≈ -1 Mais faltas → nota mais baixa

r ≈ 0 Altura do aluno → nota (sem relação)

Coeficiente de Pearson (r) 📐

A forma mais comum de medir correlação linear

🔬 **Em linguagem simples:**

Pearson divide a covariância pelo produto dos desvios padrões das duas variáveis.
Isso "normaliza" o resultado e garante que sempre fique entre -1 e +1.

0.9 a 1.0	Muito forte positiva
0.7 a 0.9	Forte positiva
0.4 a 0.7	Moderada positiva
-0.4 a +0.4	Fraca / sem relação
-0.7 a -0.4	Moderada negativa
-0.9 a -0.7	Forte negativa
-1.0 a -0.9	Muito forte negativa

Correlação no Python

df.corr() e np.corrcoef() — resultado que confirma o scatter!

```
# Forma 1 — Pandas (mais usada na prática)
corr_pandas = df[['nota','horas']].corr()
print(corr_pandas)
#           nota     horas
# nota    1.0000    0.9749
# horas   0.9749    1.0000

# Forma 2 — NumPy
r = np.corrcoef(df['nota'], df['horas'])
print(f"Pearson r = {r[0,1]:.4f}")
# Saída: Pearson r = 0.9749

# Interpretação:
# r = 0.97 → correlação MUITO FORTE positiva
# Confirma: mais horas de estudo = nota maior!
```

▶ **Resultado:**

Pearson r = 0.9749

💪 Muito forte!

r = 0.97 indica correlação quase perfeita entre horas de estudo e nota.

📊 Confirma o scatter

Esse valor confirma o padrão visual que vocês já viram no gráfico de dispersão.

🔗 Relação linear

Pearson mede apenas correlação LINEAR. Relações curvas exigem outros métodos.

Código Completo — Tudo junto! 💻

Do DataFrame ao relatório estatístico completo

```
import numpy as np
import pandas as pd

dados = {
    'aluno':  ['Ana','Bruno','Carol','Diego',
               'Elisa','Felipe','Gabi','Hugo'],
    'nota':   [8.5, 6.0, 9.2, 5.5, 7.8, 4.0, 9.0, 6.5],
    'horas':  [6,   3,   8,   2,   5,   1,   7,   4  ]}
df = pd.DataFrame(dados)

print(f"Variância:      {np.var(df['nota']):.2f}")
print(f"Desvio Padrão:  {np.std(df['nota']):.2f}")

cov = np.cov(df['nota'], df['horas'])[0, 1]
print(f"Covariância:    {cov:.2f}")

r = np.corrcoef(df['nota'], df['horas'])[0, 1]
print(f"Pearson r:      {r:.4f}")
print("Relação: MUITO FORTE POSITIVA!")
```

Resumão — Os 5 conceitos de hoje 🏆

Guarde isso e você nunca mais vai esquecer!

1

Variância (σ^2)

Média das distâncias² em relação à média. Unidade = dados ao quadrado.

```
np.var(array)
```

2

Desvio Padrão (σ)

Raiz da variância. Mesma unidade dos dados. O mais usado na prática!

```
np.std(array)
```

3

Covariância

Relação entre duas variáveis: > 0 positiva | < 0 negativa | ≈ 0 sem relação.

```
np.cov(x, y)
```

4

Pearson (r)

Força da correlação entre -1 e +1. Independe da escala dos dados.

```
np.corrcoef(x, y)
```

Parabéns! 🎉

Variância, Desvio Padrão, Covariância e Correlação de Pearson!